

Exercices supplémentaires facultatifs semaine 3

Sophie Baillargeon, Université Laval

27 janvier 2021

Dans ces exercices, vous réutiliserez les données importées dans les exercices complémentaires de la semaine 2. Ces données ont été manipulées afin de former deux jeux de données : `olympiques` et `olympiquesLarge`. Des copies de ces données ont été enregistrées dans le fichier « `ex_supp_s3.rda` ». Vous devez donc, avant de répondre aux questions 3 et 4, charger en R les objets dans ce fichier avec la fonction `load`.

```
load("C:/coursR/ex_supp_s3.rda")
```

Rappelons que ces données contiennent les nombres de médailles olympiques gagnées par le Canada et les États-Unis. Elles proviennent des pages web suivantes :

- https://fr.wikipedia.org/wiki/Canada_aux_Jeux_olympiques
- https://en.wikipedia.org/wiki/Canada_at_the_Olympics
- https://en.wikipedia.org/wiki/United_States_at_the_Olympics
- https://en.wikipedia.org/wiki/List_of_Olympic_Games_host_cities

Question 1

a)

À l'aide de la fonction `dnorm`, calculez la densité de la loi normale $N(\mu = 5, \sigma^2 = 3)$ aux points $(2, 2.5, 3, 3.5, 4, 4.5, 5, 5.5, 6, 6.5, 7, 7.5, 8)$.

b)

Implémentez maintenant vous-même la fonction de densité de la loi normale $N(\mu = 5, \sigma^2 = 3)$ afin de faire le même calcul qu'en a), mais sans faire appel à la fonction `dnorm`. Vous devez plutôt utiliser des opérateurs et fonctions mathématiques de base, en exploitant leur fonctionnement vectoriel. Stockez votre résultat dans un vecteur nommé `densNorm`. Rappel : la densité d'une loi normale $N(\mu, \sigma^2)$ est

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(\frac{-1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right).$$

c)

Arrondissez les valeurs de `densNorm` afin de conserver uniquement deux chiffres après la virgule, et stocker le résultat dans un vecteur nommé `densNorm2`.

d)

Tronquez à 0.2 les valeurs de `densNorm2`. Pour ce faire, produisez un nouveau vecteur qui contiendra, pour chaque valeur de `densNorm2`, le minimum entre la valeur et la borne 0.2.

Question 2

Pour cette question, vous utiliserez l'objet `UCBAdmissions` se trouvant dans le package `datasets` de l'installation R de base. Remarquez que cet objet est en fait une sortie de la fonction `table` qui calcule des fréquences. Avant d'utiliser ces données, nous allons d'abord transformer l'objet en data frame comme suit :

```
UCB <- as.data.frame(UCBAdmissions)
```

a)

En utilisant la fonction `xtabs`, créez, à partir du data frame `UCB`, un objet similaire à l'objet d'origine `UCBAdmissions`. Nommez ce nouvel objet `UCBAdmissions2`. Cet objet n'aura pas les mêmes attributs que `UCBAdmissions`, mais il aura la même structure.

b)

En utilisant la fonction `ftable`, créez une table qui présente les données de `UCBAdmissions` comme suit :

		Admit	Admitted	Rejected
Dept	Gender			
A	Male		512	313
	Female		89	19
B	Male		353	207
	Female		17	8
C	Male		120	205
	Female		202	391
D	Male		138	279
	Female		131	244
E	Male		53	138
	Female		94	299
F	Male		22	351
	Female		24	317

Question 3

Répondez à ces questions en utilisant le data frame `olympiquesLarge`. Ce jeu de données contient les nombres de médailles gagnées par le Canada et les États-Unis aux jeux olympiques. Il possède une ligne par événement olympique.

a)

Dans quelle(s) ville(s) le Canada a-t-il gagné plus de médailles d'or que les États-Unis?

b)

Est-ce que le Canada ou les États-Unis ont déjà réussi à gagner 15 médailles d'or ou plus à des jeux olympiques d'hiver?

c)

Est-ce que les États-Unis ont gagné au moins une médaille d'or à tous les jeux olympiques auxquels ils ont participé?

d)

À quels jeux olympiques le Canada n'a-t-il pas participé? Votre réponse devrait contenir la `Saison`, l'`Annee` et la `Ville` des jeux olympiques en question.

e)

Est-ce que des jeux olympiques ont eu lieu en 1970?

Question 4

Répondez à ces questions en utilisant les data frames `olympiquesLarge` et `olympiques`. Ces deux jeux de données contiennent les mêmes données, mais sous un format différent. Alors que le jeu de données `olympiquesLarge` possède une ligne par événement olympique, le jeu de données `olympiques` possède deux lignes par événement olympique : une pour chaque pays.

a)

Quelles sont les corrélations de Pearson observées entre toutes les paires de variables pouvant être formées à partir des variables `Or.Canada`, `Argent.Canada` et `Bronze.Canada` du jeu de données `olympiquesLarge` (ignorez les données manquantes)?

b)

Calculez le nombre moyen de médailles gagnées à des jeux olympiques d'hiver, de chaque type (or, argent et bronze) et pour chaque pays (Canada et USA), à partir du jeu de données `olympiquesLarge` (ignorez les données manquantes). Utilisez la fonction `apply` ou un de ses raccourcis. Vos résultats doivent avoir l'allure suivante :

<code>Or.Canada</code>	<code>Argent.Canada</code>	<code>Bronze.Canada</code>	<code>Or.USA</code>	<code>Argent.USA</code>	<code>Bronze.USA</code>
3.173913	2.739130	2.739130	4.565217	4.869565	3.826087

c)

Calculez les mêmes moyennes, mais cette fois-ci à partir du jeu de données `olympiques`. Utilisez la fonction `aggregate`. Vos résultats doivent avoir l'allure suivante :

	<code>Pays</code>	<code>Or</code>	<code>Argent</code>	<code>Bronze</code>
1	Canada	3.173913	2.739130	2.739130
2	USA	4.565217	4.869565	3.826087

d)

En quelle année le Canada a-t-il gagné sa centième médaille olympique à des jeux d'hiver (pas de distinction entre les médailles d'or, d'argent et de bronze)?

Question 5

Vous devez créer un code R qui simule 1000 observations pour les variables décrites dans les points suivants.

On pourrait s'imaginer que les données simulées sont des mesures prises sur les employés d'une entreprise.

a)

Une variable dichotomique nommée `x1` (valeur = 0 ou 1). La probabilité d'observer la valeur 1 doit valoir 0.6.

Fixez le germe de la génération pseudo-aléatoire avec la commande suivante `set.seed(111)` afin que tout le monde obtienne le même résultat.

On pourrait s'imaginer que cette variable représente le sexe de chaque employé (0 = homme, 1 = femme, donc environ 60% des employés de l'entreprise sont des femmes). Voici de quoi devraient avoir l'air ces observations :

```
table(x1)
```

```
## x1
##   0   1
## 389 611
```

b)

Une variable entière et non négative, nommée **x2** et simulée à l'aide d'une loi Poisson d'espérance valant 2.

Fixez le germe de la génération pseudo-aléatoire avec la commande suivante `set.seed(222)` afin que tout le monde obtienne le même résultat.

On pourrait s'imaginer que cette variable représente le nombre d'enfants de chaque employé (on va dire que c'est réaliste). Voici de quoi devraient avoir l'air ces observations :

```
table(x2)
```

```
## x2
##   0   1   2   3   4   5   6   7   8
## 141 256 288 178  89  32  10   5   1
```

c)

Une variable nommée **y** qui fera office de variable réponse. Cette variable doit être créée par la relation :

- $y = 15 + 5 * x1 + 15 * x2 + \text{epsilon}$, si $x2$ prend une valeur inférieure ou égale à 3;
- sinon par la relation $y = 15 + 5 * x1 + 15 * 3 + \text{epsilon}$.


La variable **epsilon** représente une erreur aléatoire. Cette erreur doit être générée selon une loi normale, de moyenne nulle et d'écart-type valant 5.

Fixez le germe de la génération pseudo-aléatoire avec la commande suivante `set.seed(333)` afin que tout le monde obtienne le même résultat.

On pourrait s'imaginer que cette variable représente le nombre d'heures de congé de maladie prises l'an dernier par chaque employé (encore une fois, on suppose que c'est réaliste). Voici de quoi devraient avoir l'air ces observations :

```
plot(y ~ x2, subset = x1 == 0, col = "red", pch = "*",
     main = "Relation entre y et x2 selon la valeur de x1")
points(y ~ x2, subset = x1 == 1, col = "blue", pch = "+")
legend(x = "bottomright", col = c("red", "blue"),
      legend = c("x1 = 0", "x1 = 1"), pch = c("=", "+"))
```

Relation entre y et x2 selon la valeur de x1



Question 6

Nous allons maintenant analyser les données simulées à la question 1. L'intérêt de ces analyses est que nous connaissons les résultats auxquels nous devrions approximativement arriver, puisque nous avons contrôlé la façon dont les observations ont été générées.

a)

Comparons la moyenne de y pour x1 valant 0 comparativement celle pour x1 valant 1, en suivant les étapes suivantes.

i) Avant même de calculer des statistiques descriptives, réfléchissez à quelles valeurs devraient prendre approximativement les deux moyennes en raison de la formule utilisée pour générer y. Pour faire votre estimation, fixez x2 à la valeur suivante :

```
x2moy <- mean(ifelse(x2 <= 3, x2, 3))
x2moy
```

```
## [1] 1.777
```

ii) Quelles valeurs prennent en réalité ces deux moyennes ?

iii) Est-ce que ces moyennes sont significativement différentes ?

Question pour les statisticiens : comment faire pour que le test t et l'ANOVA avec un facteur à deux niveaux effectuent exactement le même test (donc retournent exactement le même seuil observé) ?

b)

Étudions maintenant la relation entre y et x2. Nous savons que cette relation est linéaire si on se limite au sous-ensemble des données avec $x2 \leq 3$. Nous savons aussi que la valeur de l'ordonnée à l'origine de la droite représentant la relation diffère selon la valeur de x1. En fait, nous savons même que la relation devrait être approximativement $y = 15 + 5 * x1 + 15 * x2$ pour ce sous-ensemble. Ajustez un modèle de régression pour tenter de retrouver ces valeurs de paramètres.

c)


Maintenant, considérons toutes les données simulées. Ajustez simultanément sur ces données deux modèles de régression quadratique, soit un pour chaque valeur de x_1 . On peut faire ça avec un modèle global s'écrivant mathématiquement ainsi : $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 x_2^2 + \beta_5 x_1 x_2^2$.

Si vous avez nommé `reg` la sortie de la fonction `lm`, vous pouvez visualiser les modèles obtenus en soumettant les commandes suivantes :

```
plot(y ~ x2, subset = x1 == 0, col = "red", pch = "*",
     main = "Relation entre y et x2 selon la valeur de x1")
points(y ~ x2, subset = x1 == 1, col = "blue", pch = "+")
legend(x = "bottomright", col = c("red", "blue"),
      legend = c("x1 = 0", "x1 = 1"), pch = c("?", "+"))

jeu <- data.frame(y, x1, x2, pred = fitted(reg))
jeu <- jeu[order(jeu$x2),]
lines(pred ~ x2, data = jeu, subset = x1 == 0, col = "red", lwd = 2)
lines(pred ~ x2, data = jeu, subset = x1 == 1, col = "blue", lwd = 2)
```

Relation entre y et x2 selon la valeur de x1



Question 7

La fonction `lm` ajuste en fait des modèles linéaires par la méthode des moindres carrés. Notons de façon matricielle le modèle comme suit :

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

où

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ x_{21} & \cdots & x_{2p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

Selon la méthode des moindres carrés, l'estimateur des paramètres beta est donné par la formule

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Ces formules sont tirées de la page web : http://en.wikipedia.org/wiki/Multiple_regression

a)

Reprenons le modèle ajusté sur le sous-ensemble des données avec $x_2 \leq 3$ à la question 2 b). Retrouvez les estimations de paramètres

$$\hat{\beta}^T = (15.22, 5.402, 14.788)$$

en utilisant la formule donnée ci-dessus.

b)

Reprenons maintenant le modèle ajusté à la question 2 c). Retrouvez les estimations de paramètres

$$\hat{\beta}^T = (14.1529, 4.45, 19.5166, 0.9201, -1.886, -0.2266)$$

en utilisant la formule donnée ci-dessus.