

Exercices supplémentaires facultatifs semaine 4

Sophie Baillargeon, Université Laval

Dans ces exercices, vous réutiliserez les données importées dans les exercices supplémentaires de la semaine 2. Afin de s'assurer que tout le monde travaille sur les mêmes objets, veuillez utiliser les data frames `CanadaEte`, `CanadaHiver`, `USAete`, `USAHiver` et `villesHotes`, dont des copies ont été enregistrées dans le fichier « `ex_supp_s4.rda` ». Vous devez donc charger en R les objets dans ce fichier avec la fonction `load`.

```
load("ex_supp_s4.rda")
```

Rappelons que ces données contiennent les nombres de médailles olympiques gagnées par le Canada et les États-Unis. Elles proviennent des pages web suivantes :

- https://fr.wikipedia.org/wiki/Canada_aux_Jeux_olympiques
- https://en.wikipedia.org/wiki/Canada_at_the_Olympics
- https://en.wikipedia.org/wiki/United_States_at_the_Olympics
- https://en.wikipedia.org/wiki/List_of_Olympic_Games_host_cities

Étape par étape, vous créerez les jeux de données `olympiques` et `olympiquesLarge` manipulés dans les exercices supplémentaires de la semaine 3.

Question 1

Le but de cette question est de mettre en commun les data frames `CanadaEte`, `CanadaHiver`, `USAete` et `USAHiver` en un seul jeu de données. Nous allons procéder par étapes :

- a) Le jeu de données `CanadaEte` comporte plusieurs différences par rapport aux autres, notamment des annotations en anglais alors que les autres fichiers sont annotés en français. Il faudrait :
- retirer la variable `Athletes`, qui n'est pas présente dans les autres jeux de données;
 - retirer la ligne contenant des totaux, ainsi que l'observation pour les jeux olympiques à Tokyo en 2020, qui ont finalement été reportés;
 - retirer les noms des villes des observations de la variable `Games` de façon à ne conserver que les années;
 - renommer les variables restantes en français, en reprenant les noms dans les autres jeux de données;
 - remplacer les données `"did not participate"` par des NA.

Il serait préférable d'effectuer toutes ces modifications dans une copie de `CanadaEte`.

- b) Le jeu de données combiné devra contenir 2 nouvelles variables en plus des 6 déjà existantes (`annee`, `or`, `argent`, `bronze`, `total` et `rang`). Ces 2 nouvelles variables doivent être **placées avant les 6 autres**. Il s'agit des variables :
- `pays` qui doit prendre la valeur `"Canada"` ou `"USA"` selon qu'il s'agisse de nombres de médailles pour le Canada ou pour les États-Unis,
 - `saison` qui doit prendre la valeur `"ete"` ou `"hiver"` selon qu'il s'agisse de nombres de médailles gagnées lors de jeux olympiques d'été ou d'hiver.

Il est préférable d'ajouter ces deux variables à des copies des jeux de données `CanadaEte`, `CanadaHiver`, `USAete` et `USAHiver`, avant de les combiner.

- c) Combiner les observations des jeux de données `CanadaEte`, `CanadaHiver`, `USAete` et `USAHiver`, afin de former un jeu de données contenant 8 variables et $28 + 23 + 28 + 23 = 102$ d'observations. Nommer le nouveau jeu de données combinées **olympiques**.
- d) Les colonnes du jeu de données **olympiques** doivent être des types suivants :
- facteur : `pays` et `saison`.
 - vecteur numérique : `annee`, `or`, `argent`, `bronze`, `total` et `rang`.

Rendre la variable `rang` numérique vous demandera plus de travail que pour les autres variables. Il faut retirer les caractères "e" et "er" avant d'effectuer la conversion de type des valeurs.

Question 2

Vous devez maintenant retravailler le jeu de données **olympiques**.

- a) Ajoutez au jeu de données **olympiques** une colonne pour la ville hôte en fonction de la saison et de l'année. Pour ce faire, vous devez :
- fusionner par association les jeux de données **olympiques** et `villesHotes` en utilisant la fonction `merge`. Nommez le jeu de données obtenu **olympiques**, ce qui remplacera l'ancien jeu de données par le nouveau.
- Note** : Dans le jeu de données `villesHotes`, on retrouve 2 villes hôtes aux jeux d'été en 1956. Ces jeux olympiques ont principalement eu lieu à Melbourne, mais les épreuves équestres ont eu lieu à Stockholm. Afin d'avoir une seule ligne par jeux olympiques dans `villesHotes`, retirez la ligne pour la ville hôte Stockholm en 1956.
- Conserver du résultat de la fusion uniquement les variables suivantes, en respectant l'ordre ci-dessous : `pays`, `saison`, `annee`, `City`, `or`, `argent`, `bronze`, `total` et `rang`; et renommez `ville` la colonne nommée `City`.
- b) Ordonnez les lignes du jeu de données **olympiques** selon l'année, en débutant par l'année la plus récente.
- c) Modifiez les noms de colonnes de **olympiques** de façon à ce que la première lettre de tous les noms soit une majuscule, et que les autres lettres formant les noms soient en minuscules.
- d) Ajoutez au jeu de données **olympiques** une variable nommée `TotalMoyen` contenant, pour chacun des jeux olympiques, la moyenne du nombre total de médailles gagnées par le Canada ou les États-Unis (moyenne de deux valeurs). Les valeurs dans cette nouvelle colonne seront toutes en double, comme pour la ville hôte les pays.

Question 3

Pour répondre aux questions suivantes, vous devez créer de nouveaux jeux de données à partir de **olympiques**. Cependant, laissez tomber les variables `Total`, `Rang` et `TotalMoyen`. Elles ne seront pas utiles.

- a) Créez le jeu de données **olympiquesLong** qui doit combiner les nombres de médailles `Or`, `Argent` ou `Bronze` dans une seule colonne. Ce jeu de données doit contenir une nouvelle colonne pour identifier le type des médailles dénombrées. Le nouveau jeu de données contiendra 3 fois plus de lignes que le jeu de données **olympiques**. Il s'agit d'une remise en forme vers un format plus long.
- b) Créez le jeu de données **olympiquesLarge** qui doit contenir une colonne par pays pour chaque type de médailles (ex. médailles d'or canadiennes, médailles d'or américaines, médailles d'argent canadiennes, etc.). Le nouveau jeu de données contiendra 2 fois moins de lignes que le jeu de données **olympiques**. Il s'agit d'une remise en forme vers un format plus large.

- c) Ajoutez à `olympiquesLarge` une colonne, nommée `MeilleurOr`, contenant le nom du pays ayant gagné le plus de médailles d'or entre le Canada et les USA. En cas d'égalité, la variable devrait prendre la valeur `"egalite"`.