Comprendre les données du défi 2

Guide de prise en main · STT-4230 / STT-6230

Une même commande, avant et après

Une coopérative canadienne fictive achète trois lots de marchandises provenant des États-Unis. Un lot est un ensemble de produits auquel on associe une valeur totale en dollars canadiens. Pour prévoir le coût de sa commande, la coopérative veut connaître la surtaxe qui s'ajouterait à la valeur des marchandises.

Dans cette simulation, une surtaxe est un montant calculé en appliquant un taux en pourcentage à la valeur du lot. Le taux à retenir dépend du produit et de la date étudiée. La coopérative compare donc sa commande à deux dates d'essai : le 20 août 2025, avant le changement de tarifs, et le 10 septembre 2025, après ce changement.

Les produits et leurs valeurs restent les mêmes aux deux dates. On cherche à comprendre comment le changement de tarifs modifie la surtaxe totale de cette même commande.

Situation d'essai	Date étudiée	Commande
Avant : `avant_exemple`	20 août 2025	Les trois lots de `lots_essai.csv`
Après : `apres_exemple`	10 septembre 2025	Les mêmes trois lots, avec les mêmes valeurs

Les lots, les valeurs et les deux scénarios d'essai sont fictifs. Ils servent à comprendre les fichiers. Les lots et les dates de l'épreuve seront différents et resteront réservés à 13 h 30.

Ce que vous recevez

Avant l'épreuve	Le 21 octobre à 13 h 30
Le projet RStudio à ouvrir et à tester	Les lots et les scénarios de l'épreuve
Le fichier des taux et son dictionnaire	L'énoncé et les règles de calcul
Les fichiers d'essai et ce guide	Le rapport QMD à compléter et le code à examiner

Le code et le rapport évalués seront rédigés pendant l'épreuve, de 13 h 30 à 14 h 30. Aucune connaissance douanière n'est nécessaire ; l'énoncé donnera les règles de simulation.

Comment les trois fichiers sont-ils reliés ?

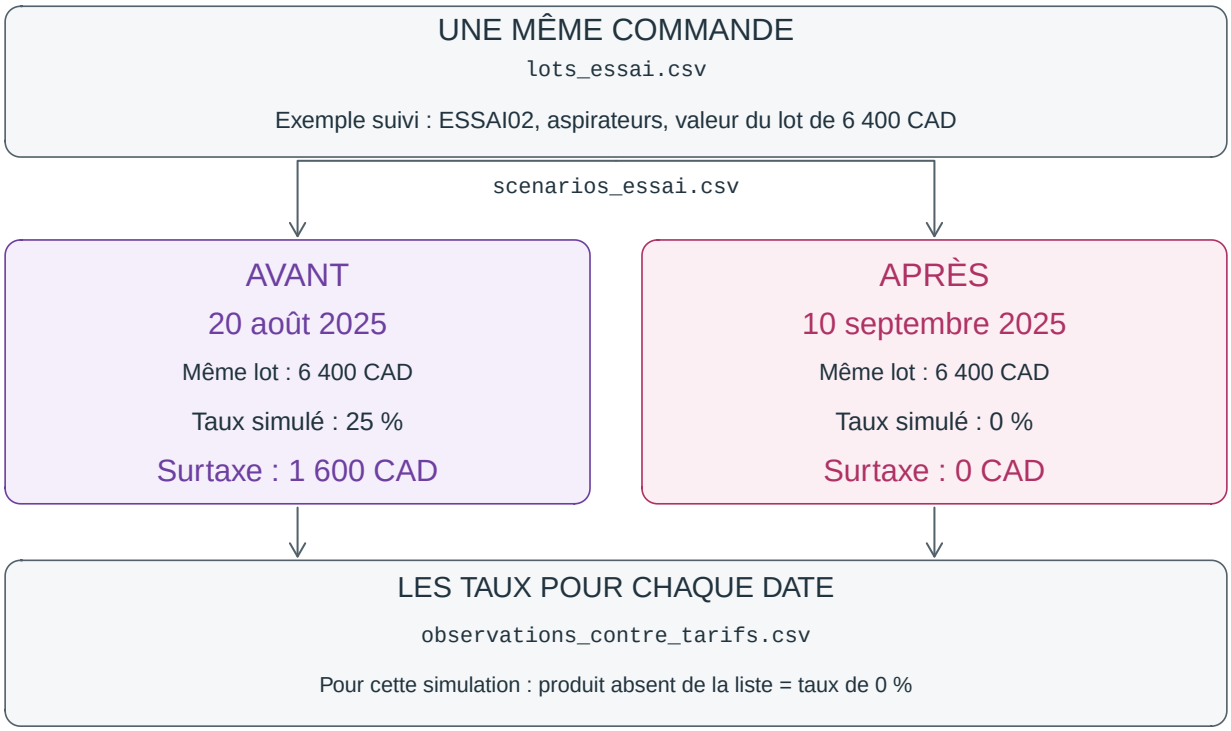

Les lots décrivent ce qu'on importe. Les scénarios indiquent quand on l'observe. Le fichier des taux permet d'associer les taux aux produits pour chacune des deux situations.

Dans cet exemple, le code de l'aspirateur est présent dans la liste du 20 août, au taux de 25 %, et absent de celle du 10 septembre. Pour cette simulation, on attribue un taux de 0 % au produit absent de la liste à la date étudiée. La surtaxe passe donc de 1 600 CAD à 0 CAD, alors que le lot vaut toujours 6 400 CAD.

À quoi ressemblent les lots ?

Lot	Code tarifaire	Libellé fictif	Valeur (CAD)
ESSAI01	07020010	Tomates, exemple fictif	1250
ESSAI02	85081100	Aspirateurs, exemple fictif	6400
ESSAI03	94013110	Sièges, exemple fictif	875

`ESSAI02` est un lot fictif d'aspirateurs d'une valeur totale de 6 400 CAD. Cette valeur porte sur le lot entier. On réutilise ce même lot pour les deux scénarios.

Conservez les codes comme du texte : le zéro au début de `07020010` fait partie du code. Les codes sont fournis ; vous n'avez pas à classer les marchandises.

Les colonnes qui relient les fichiers

Les extraits ci-dessous montrent les noms des colonnes et les valeurs qui permettent de relier les fichiers. Les deux scénarios « avant » et « après » restent visibles.

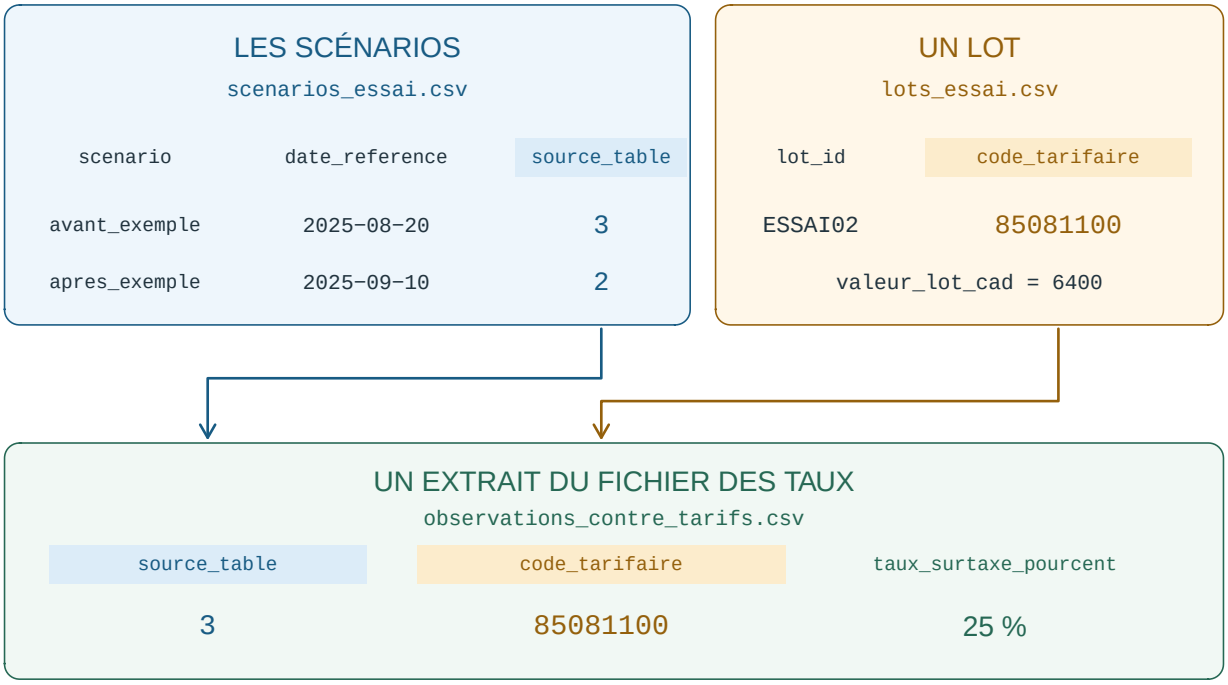

Même nom de colonne, même couleur : les clés de liaison.

`source_table`, en bleu, relie chaque scénario aux lignes de taux qui lui correspondent. `code_tarifaire`, en orange, relie le produit d'un lot au même code dans le fichier des taux.

Pour retrouver le taux d'un lot dans un scénario, on utilise ces deux informations ensemble. Le fichier complet contient les autres lignes ; ce dessin en montre seulement un extrait.

À quoi ressemblent les scénarios ?

Voici les deux situations de `scenarios_essai.csv` :

Scénario	Date de référence
avant_exemple	2025-08-20
apres_exemple	2025-09-10

Une ligne est une situation, à une date donnée. Chaque situation s'applique à toute la commande. Les dates du CSV suivent le format année-mois-jour.

Le CSV contient aussi `source_table`, un repère déjà fourni pour associer les taux à la date du scénario. L'énoncé fournira également ce repère pour les scénarios de l'épreuve.

Où trouve-t-on les taux ?

`observations_contre_tarifs.csv` contient 2774 lignes et 19 colonnes. Il rassemble des taux pour plusieurs périodes. Une ligne décrit un produit, identifié par son code, dans une période donnée.

Colonne	À quoi elle sert
`code_tarifaire`	Reconnaître le produit du lot
`source_table`	Associer la ligne de taux au scénario daté
`taux_surtaxe_pourcent`	Lire le taux en pourcentage

Les valeurs des lots sont en dollars canadiens. Les taux sont des pourcentages. `NA` indique une information manquante dans le fichier des taux. L'énoncé donnera les règles à appliquer pour calculer les surtaxes.

Le dictionnaire complet explique toutes les colonnes. Certaines descriptions contiennent des retours à la ligne ; un éditeur de texte peut donc afficher plus de lignes que le nombre de lignes lues par R.

Avant la séance

1. Ouvrez `defi-2.Rproj`, puis les trois CSV. Repérez les lots et les deux dates d'essai.
2. Exécutez la vérification technique et testez le rendu HTML du guide.
3. Testez un commit et un push. Le README donne les étapes.

`guide-donnees.qmd` est la source de ce guide. À 13 h 30, vous recevrez un autre QMD, `rapport-defi-2.qmd`, pour rédiger votre rapport.

Sources et limites

Les taux viennent du ministère des Finances du Canada, à partir des données préparées par Données bleues. Leur provenance et les conditions de réutilisation figurent dans `data/SOURCE.md` et `data/DATA_LICENSE.md`.

Les montants du défi seront des simulations. Les données ne suffisent pas à établir une facture douanière réelle.