Comprendre les données du défi 2

Guide de prise en main · STT-4230 / STT-6230

Le contexte

Une entreprise fictive importe des marchandises. Elle dispose de lots, chacun associé à un code tarifaire et à une valeur en dollars canadiens. Des tableaux documentaires indiquent des taux de surtaxe selon les produits et les périodes.

Le défi utilisera ces trois types de fichiers. Vous n'avez besoin d'aucune expertise douanière : les codes seront fournis et l'énoncé donnera les règles de simulation.

Ce qui est disponible et à quel moment

Avant la séance	Le 21 octobre à 13 h 30
Projet RStudio, guide, dictionnaire et vérification technique	Énoncé et règles de simulation
Tableaux tarifaires documentaires	Lots et scénarios exacts à analyser
Trois lots d'essai et un scénario fictif	Canevas QMD et proposition de code à examiner

Les exemples de ce guide permettent de comprendre les colonnes. Ils ne donnent pas les lots ni les paramètres du défi. La rédaction du code et du rapport évalués commence à 13 h 30.

Les fichiers à reconnaître

Fichier de prise en main	Son rôle	Une ligne représente
`lots_essai.csv`	Décrire les marchandises	Un lot fictif
`scenarios_essai.csv`	Décrire une situation datée	Un scénario fictif
`observations_contre_tarifs.csv`	Documenter les taux et leur provenance	Un code dans un tableau historique

À 13 h 30, les fichiers à analyser s'appelleront `lots_importation.csv` et `scenarios.csv`. Ils auront les mêmes colonnes que leurs fichiers d'essai. Le fichier tarifaire documentaire sera le même que celui déjà fourni.

Lire les lots d'essai

Les trois lignes ci-dessous sont lues dans `lots_essai.csv`. Les identifiants, libellés et valeurs sont fictifs.

Lot	Code tarifaire	Libellé fictif	Valeur (CAD)
ESSAI01	07020010	Tomates, exemple fictif	1250
ESSAI02	85081100	Aspirateurs, exemple fictif	6400
ESSAI03	94013110	Sièges, exemple fictif	875

Un lot représente un ensemble de marchandises auquel on associe une valeur. Par exemple, la ligne `ESSAI02` décrit un lot fictif d'aspirateurs d'une valeur de 6 400 CAD, pas nécessairement un seul appareil.

Colonne	Comment la lire
`lot_id`	Identifiant du lot, comme `ESSAI01`
`code_tarifaire`	Référence à huit chiffres, à conserver comme texte
`libelle_pedagogique`	Description simplifiée pour lire l'exemple
`valeur_lot_cad`	Valeur du lot en dollars canadiens

Le zéro initial de `07020010` fait partie du code. Ce code est un identifiant, pas une quantité sur laquelle effectuer un calcul. Les codes fournis ne vous demandent pas de classer vous-même les marchandises.

Lire le scénario d'essai

Scénario	Date de référence	Tableau associé
exemple	2025-08-20	3

Colonne	Comment la lire
`scenario`	Nom qui identifie une situation
`date_reference`	Date écrite au format année-mois-jour
`source_table`	Identifiant d'un tableau du fichier tarifaire

La date et le tableau de cet exemple servent à montrer le format. Les scénarios exacts et les règles de calcul du défi seront fournis à 13 h 30.

Lire le fichier tarifaire documentaire

`observations_contre_tarifs.csv` contient 2774 observations et 19 colonnes. Ces taux proviennent de données documentaires préparées par Données bleues à partir du ministère des Finances du Canada. Ils ne sont pas inventés pour ce guide.

Une ligne décrit un code dans un tableau historique. Le fichier regroupe trois tableaux, repérés par `source_table`. Un même code peut donc apparaître dans plusieurs tableaux associés à des périodes différentes.

Colonnes qui décrivent le produit, le taux et la période

Colonne	Signification
`source_table`	Identifiant du tableau historique : `1`, `2` ou `3`
`code_tarifaire`	Code canadien à huit chiffres, à conserver comme texte
`code_affiche_source`	Écriture du code dans le document source
`code_sh6`	Préfixe du code à six chiffres
`position_source`	Intitulé de la catégorie dans la source
`description_source`	Description documentaire de la marchandise
`taux_surtaxe_pourcent`	Taux exprimé en pourcentage
`date_application_initiale_source`	Date initiale renseignée par la source, lorsqu'elle est disponible
`periode_table_source`	Libellé de la période du tableau
`debut_periode_table_source`	Début de cette période, lorsqu'il est renseigné
`fin_periode_table_source_inclusive`	Dernier jour de cette période, lorsqu'il est renseigné

Le taux est exprimé en pourcentage ; la valeur d'un lot est exprimée en dollars canadiens. Ce sont deux unités différentes. Les formules à utiliser seront données dans l'énoncé.

Les descriptions de marchandises peuvent contenir des retours à la ligne. Le nombre de lignes affiché par un éditeur de texte peut donc dépasser le nombre d'observations réellement lues dans le CSV.

Colonnes qui documentent la provenance

Colonne	Signification
`collection_id`	Identifiant de la collecte documentaire
`source_id`	Identifiant du document source
`source_row`	Repère de ligne fourni lors de l'extraction
`pays_percepteur`	Pays percepteur : `CAN` dans ce fichier
`pays_origine`	Pays d'origine : `USA` dans ce fichier
`nomenclature`	Nomenclature utilisée dans la source
`statut_validation`	Mention des limites de validation et des conditions non résolues
`observed_at_utc`	Horodatage UTC fourni dans les données documentaires

Ces colonnes décrivent l'origine et les limites des observations. Les données ne suffisent pas, à elles seules, à établir une facture douanière réelle.

Vérifier sa compréhension avant la séance

Vous devriez pouvoir expliquer ce que représente une ligne dans chacun des trois fichiers, reconnaître les identifiants, lire les dates et distinguer un taux d'une valeur monétaire.

Les CSV sont en UTF-8. `NA` indique une information absente dans le fichier documentaire. Le dictionnaire complet reprend les colonnes et leurs unités.

Ouvrir `defi-2.Rproj`, lancer `scripts/verifier-environnement.R`, puis tester un commit et un push. Le guide est fourni en PDF et en HTML. Son fichier `guide-donnees.qmd` permet aussi de tester un rendu HTML depuis le projet, sans installation LaTeX.

À 13 h 30, le paquet de départ ajoutera les vrais fichiers de lots et de scénarios dans `data/`, ainsi que l'énoncé et le canevas à la racine du projet. Les fichiers d'essai resteront distincts.

Sources et droits

Données bleues, tarifs douaniers, à partir des données du ministère des Finances du Canada. Les conditions et l'attribution figurent dans `data/SOURCE.md` et `data/DATA_LICENSE.md`.